

7장_Trnasformer(BERT~)

BERT



BERT(Bidirectional Encoder Representations from Transformers)

- 2018 구글 발표 언어모델: 트랜스포머 기반 양방향 인코더
- 양방향 문장 학습 → 전후의 단어 모두 참조: 의미, 문맥 파악 용이
- 트랜스포머의 인코더 모듈만을 사용
- 사전학습을 위해 MLM, NSP 사용
 - MLM: 마스킹된 언어 모델링
 - NSP: 다음 문장 예측 방법




그림 7.13 트랜스포머와 BERT 모델 비교

▼ 사전학습 방법

- 마스크된 언어 모델링(Masked Language Modeling, MLM)
: 입력 문장에서 임의로 일부 단어를 마스크하고 해당 단어를 예측하는 방식
 - 이 과정에서 양방향 문맥 정보 참고
 - 양방향 문장 학습 → 입력 문장에서 누락된 단어 추론 가능
- 다음 문장 예측(Next Sentence Prediction, NSP)
: 두 개의 문장이 주어졌을 때, 두 번째 문장이 첫 문장의 다음인지 판단
 - 두 문장이 연속적인 관계인지 아닌지 예측
 - 이때 두 문장 간 관계, 의미적 유사성 파악
- 특수 토큰
: 입력 문장에 특수 토큰 추가 → 학습, 추론 과정에서 필요한 정보 제공
ex) **[CLS]** 문장-1 **[SEP]** 문장-2 **[MASK]** **[SEP]** 등의 구조를 가질 수 O



BERT의 특수 토큰

- **[CLS]** 토큰: 입력 문장의 시작 부분에 추가되는 토큰
 - 문장 분류 작업을 위한 정보 제공
 - 입력 문장의 유형 파악: ex) 긍/부, 문장 내 어떤 객체가 언급되는지
 - **[SEP]** 토큰: 입력 문장 내에서 두 개의 문장을 구분하기 위해 사용되는 토큰
 - **[MASK]** 토큰: 입력 문장 내 임의로 선택된 단어를 가리키는 특별 토큰
 - 주어진 문장에서 일부 단어를 가린 후, 학습과 예측에 활용
 - ex) 언어 모델링 작업에서 → 마스크된 실제 단어 예측에 사용
-
- **[MASK]** 토큰 적용 방법: 텍스트 토큰 중 15%의 단어를 마스크
 - 80%: **[MASK]** 토큰으로 대체
 - 10%: 어휘 사전에 존재하는 무작위 단어로 변경

- 10%: 실제 토큰을 그대로 사용
- 분류 문제에서는 일반적으로 [CLS] 토큰 벡터 사용
각 토큰마다 예측이 필요한 경우 모든 토큰 벡터 사용



미세조정 방법

해당 작업에 맞는 계층 추가 → 손실 함수를 정의해 학습

▼ 모델 실습



BERT 모델 실습

- 모델: 허깅페이스 트랜스포머스 라이브러리의 BERT 모델
- 데이터셋: 네이버 영화 리뷰 감정 분석 데이터셋

BART




BART(Bidirectional Auto-Regressive Transformer)

- 2019 메타의 FAIR 연구소에서 발표한 트랜스포머 기반의 모델
- **Seq2Seq 구조**: BERT의 인코더 + GPT의 인코더 결합
 - BERT 인코더: 입력 문장에서 일부 단어를 무작위 마스킹 → 맞추도록 학습
 - GPT 인코더: 문장의 이전 토큰을 입력으로 받고 → 다음 토큰 맞추도록 학습
 - BART 사전학습 시: BERT, GPT 인코더의 학습방법을 일반화
- 노이즈 제거 오토인코더로 사전 학습
 - 입력 데이터에 잡음을 추가
 - → 잡음이 없는 원본 데이터를 복원하도록 학습

▼ BART 개괄

- **BERT와 BART의 차이점**

- BERT: 인코더만 사용
- BART: 인코더와 디코더 모두 사용 → 트랜스포머와 유사한 구조
 - ⇒ 문장 독해, 문서 요약, 질의응답 등에 높은 성능
 - 트랜스포머: 인코더의 모든 계층과 디코더의 모든 계층 사이 어텐션 연산 수행
 - BART: 인코더의 마지막 계층과 디코더의 각 계층 사이에만 어텐션 연산 수행
 - ⇒ 정보 전달 최적화, 메모리 사용량 절약



• BART 인코더와 디코더

- 인코더: 입력 문장의 각 단어 임베딩
- 인코더 마지막 계층에서 전체의미 반영 벡터 생성
→ 이 벡터는 디코더가 출력 문장을 생성할 때 참고됨
- 디코더: 각 계층에서 이전 계층에서 생성된 출력 문장의 정보 활용 → 문장 생성

▼ 사전학습 방법: 노이즈 제거 오토인코더 사용



BART 사전학습 개괄




그림 7.15 BART 사전 학습 시각화

- 입력 문장에 임의로 노이즈 추가 → 원래 문장 복원하도록 학습
 - 노이즈가 추가된 텍스트를 인코더에 입력
 - 원본 텍스트를 디코더에 입력
 - ⇒ 디코더가 원본 텍스트를 생성할 수 있게 학습
- BERT와 GPT의 학습방법을 결합한 것임
 - ⇒ BART는 문장구조, 의미를 보존하며 다양한 변형 학습 가능
 - 입력 문장에 큰 제약 없이 노이즈 기법을 적용할 수 있는 구조
 - → 더 풍부한 언어적 지식 습득 가능
- 인코더와 디코더 모두 사용
 - 인코더 사용: 순방향 정보만 인식할 수 있는 GPT의 단점 개선 → 양방향 문맥 반영
 - 디코더 사용: 문장 생성 분야에서 뛰어나지 못했던 BERT의 단점 개선

- BART 사전 학습에 사용되는 여러 노이즈 기법
 - BERT의 MLM 이외에도 다양한 노이즈 기법 사용

- 토큰 삭제, 문장 교환, 문서 회전, 텍스트 채우기 등
- 모델은 연속된 마스크 토큰을 복구하되, 실제로는 마스킹X 토큰도 구분해야 함
→ 누락된 단어를 예측하게 유도 → 더 많은 정보 활용해 입력 문장 더 잘 이해



1. 토큰 마스킹(Token Masking)

: 입력 문장의 일부 토큰을 마스크 토큰으로 치환

- BERT에서 사용한 MLM 과 동일한 기법
- 문장 내에서 어떤 단어가 중요한 역할을 하는지 학습 가능
- 입력 문장의 문맥 이해, 문장 내에서 중요한 정보를 추출하는 능력 향상

2. 토큰 삭제(Token Deletion)

: 입력 문장의 일부 토큰 치환 X, 삭제 O

- 토큰 마스킹과 달리, 어떤 위치의 토큰이 삭제되었는지도 맞춰야 함
- 입력 문장에서 불필요한 정보, 중요하지 않은 정보 자동 필터링 가능해짐
- 모델의 학습, 예측시간 단축 / 모델의 일반화 성능 향상 가능

3. 문장 순열(Sentence Permutation)

: 마침표를 기준으로 문장을 나눈 뒤 → 문장의 순서를 섞는 방법

- 원래 문장의 순서를 맞춰야 함
- 문장 내에서 단어들이 어떻게 연결되어 있는지 더 잘 파악하게 됨
- 입력 문장이 다른 순서로 주어졌을 때도 잘 처리하게 됨

4. 문서 회전(Document Rotation)

: 임의의 토큰으로 문서가 시작하도록 함

- 문장 순열과 달리, 문장의 순서 유지
- 모델은 문서의 원래 시작 토큰을 맞춰야 함
- 모델이 문서의 시작점을 인식할 수 있도록 함

5. 텍스트 채우기(Text Infilling)

: 몇 개의 토큰을 하나의 구간(span)으로 묶고 일부 구간을 마스크 토큰으로 대체

- 묶은 구간의 길이(개수)는 0부터 임의의 값까지 설정할 수 O
- 일반적으로 포아송 분포로 구간을 나눔
(Poisson distribution의 λ 를 3으로 설정해 계산)
- 구간의 길이가 0인 경우: 해당 위치에 변환된 토큰이 없다는 의미

▼ 미세조정 방법



BART의 미세 조정 방법




그림 7.18 BART 미세 조정 구조

- BART는 인코더와 디코더를 모두 사용하는 구조
⇒ 미세 조정 시 각 다운스트림 작업에 맞게 입력 문장 구성해야 함
- 즉, 인코더와 디코더에 각각 다른 문장 구조를 입력
- BART의 다운스트림 작업별 미세 조정 방법

• 문장 분류 작업

- 입력 문장을 인코더와 디코더에 동일하게 입력
- 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 사용

- BERT의 CLS 토큰과 비슷 / BUT, 전체 입력과 어텐션 연산이 적용된 은닉 상태 사용
- 토큰 분류 작업
 - 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 각 시점별 마지막 은닉 상태를 토큰 분류기의 입력으로 사용
 - 전체 입력과 디코더의 각 시점별 은닉 상태와의 어텐션 연산 수행
- BART는 디코더를 사용 → 문장생성 가능
 - 특히 추상적 질의응답(Abstractive Question Answering), 문장 요약 작업에 적합
 - 추상적 질의응답: 입력값을 조작해 출력 생성
 - 위 작업들은 BART의 사전학습 방식과 유사 → 뛰어난 성능
 - ex) 기계 번역: BART는 사전학습된 인코더에 기계번역용 인코더를 추가해 작업
 - 추가된 인코더: 기존의 단어 사전을 사용하지 않아도 됨
 - 디코더: 사전 학습된 가중치, 단어 사전 사용

ELECTRA



ELECTRA

: Efficiently Learning an Encoder that Classifies Token Replacements Accurately

- 2020 구글에서 발표 / 트랜스포머 기반의 모델
- 기존 모델과의 차이점
 - 대부분의 NLP 모델: MLM or 일부 토큰을 [MASK]로 대체하는 방식 사용
→ 입력을 손상시키고, 원래 토큰을 복원하는 모델 학습
 - ELECTRA: 입력 마스킹 X, 생성자와 판별자 사용해 사전학습 O
 - 변환기 모델인 생성자와 판별자를 학습
 - → 생성적 적대 신경망(GAN)과 유사한 방법으로 학습 수행
 - (모델의 매개변수 수) BERT 등 > ELECTRA
- 생성자와 판별자
 - 생성 모델: 실제 데이터와 비슷하게 토큰 생성 → 다른 토큰으로 대체
 - 판별 모델: 생성 모델이 만든 데이터 + 실제 데이터 입력받아 ⇒ 둘을 구분
- GAN을 사용해 학습 → 더 효율적인 학습 가능
 - 대규모 데이터셋에서 더 빠르게 모델 학습
 - 생성 모델을 통해 토큰 생성 → 보다 자연스러운 문장 생성

▼ 사전학습 방법

- 생성자와 판별자: 모두 트랜스포머 인코더 구조
 - 생성자 모델: 입력 문장의 일부 토큰 마스크 처리 / 마스크된 토큰 예측하며 학습
 - 판별자 모델: 각 입력 토큰의 출처(원본or생성자) 맞히며 학습



RTD(Replaced Token Detection)

T5

▼ 모델 실습

- 코드 참고